

学习单域泛化

Fengchun Qiao
University of Delaware
fengchun@udel.edu

Long Zhao
Rutgers University
lz311@cs.rutgers.edu

Xi Peng
University of Delaware
xipeng@udel.edu

摘要

We are concerned with a worst-case scenario in model generalization, in the sense that a model aims to perform well on many unseen domains while there is only one single domain available for training. We propose a new method named adversarial domain augmentation to solve this Out-of-Distribution (OOD) generalization problem. The key idea is to leverage adversarial training to create “fictitious” yet “challenging” populations, from which a model can learn to generalize with theoretical guarantees. To facilitate fast and desirable domain augmentation, we cast the model training in a meta-learning scheme and use a Wasserstein Auto-Encoder (WAE) to relax the widely used worst-case constraint. Detailed theoretical analysis is provided to testify our formulation, while extensive experiments on multiple benchmark datasets indicate its superior performance in tackling single domain generalization.

1. 引言

近年来，机器学习模型在广泛应用中快速部署[17, 42, 3, 60]。其显著成功背后的一个关键假设是训练数据和测试数据通常遵循相似的统计分布。否则，即使是强模型（e.g., 深度神经网络）也可能在未见或分布外（OOD）测试域中失效[2]。整合多个训练域的数据在一定程度上缓解了这一问题[21]，但由于数据获取预算或隐私问题，这并非总是可行。于是出现了一个有趣但鲜少研究的问题：模型能否从一个源域泛化到多个未见的目标域？换言之，当仅有一个训练域可用时，如何最大化模型的泛化能力？

源域与目标域之间的差异，也称为域或协变量偏移[48]，已在domain adaptation[30, 33, 57, 24]和domain generalization[32, 9, 22, 4]中得到深入研究。尽管它们




图1. 领域差异: (a) 领域适应, (b) 领域泛化, 以及(c) 单领域泛化。

在处理普通领域差异问题上取得了各种成功，然而，我们认为现有方法难以在上述单一领域泛化问题中取得成功。如图1所示，前者通常期望目标领域数据（无论是否标注）可用；而后者则始终假设训练时存在多个（而非一个）领域。这一事实强调了为single domain generalization开发新学习范式的必要性。

在本文中，我们提出adversarial domain augmentation (第3.1节)来解决这一具有挑战性的任务。受近期对抗训练成功案例的启发[35, 50, 49, 36, 24]，我们将单域泛化问题置于最坏情况公式化框架中[44, 20]。目标是利用单一源域生成“虚构”但“具有挑战性”的样本群体，使模型能够从中学习并具备理论保证的泛化能力（第4节）。

然而，将对抗训练应用于领域增强时存在技术障碍。一方面，由于最坏情况公式中语义一致性约束[11]的矛盾，难以创建与源领域差异较大的“虚构”领域。另一方面，我们希望探索大量“虚构”领域以保证充分覆盖，但这可能导致显著的计算开销。为克服这些障碍，我们提出通过Wasserstein自编码器（WAE）[52]实现relax the worst-case constraint(第3.2节)，以鼓励输入空间中的大范围领域迁移。此外，我们并非学习一系列集成模型[56]，而是通过meta-learning[6]（第3.3节）组织对抗性领域增强，从而生成一个高效模型，并提升单领域泛化能力。

¹The source code and pre-trained models are publicly available at: <https://github.com/joffery/M-ADA>.

这项工作的主要贡献在于提出了一种基于元学习的方案，实现了单域泛化——一个重要但鲜少被研究的问题。我们通过提出对抗性域增强来实现这一目标，同时放宽了广泛使用的最坏情况约束。我们还提供了详细的理论理解来验证我们的解决方案。大量实验表明，我们的方法在包括*Digits*、*CIFAR-10-C* [14]和*SYTHIA* [37]在内的基准数据集的单域泛化中，以微弱优势超越了现有技术水平。

2. 相关工作

领域差异：由领域或协变量偏移[48]带来的领域差异严重降低了模型在跨域识别中的性能。使用经验风险最小化[16]训练的模型通常在未见过的领域上表现不佳。为减少跨域差异，一系列方法被提出用于无监督[33, 43, 7, 38, 39]或有监督领域适应[31, 57]。近期一些工作也关注少样本领域适应[30]，其中仅涉及目标域中的少量标注样本参与训练。

与领域自适应不同，领域泛化旨在从多个源领域学习，而无需访问目标领域。以往大多数方法要么尝试学习一个领域不变空间来对齐领域[32, 9, 12, 21, 59]，要么聚合特定领域的模块[29, 28]。最近，Carlucci *et al* [4]通过联合学习图像中的监督信号和无监督信号解决了这一问题。在数据层面，基于梯度的领域扰动[41]和对抗训练方法[56]被提出以提高泛化能力。特别地，[56]专为单领域泛化设计，并通过集成模型实现了更优性能。与[56]相比，我们旨在为“虚构”领域创建大规模领域迁移，并在单一统一模型内设计更高效的元学习方案。

对抗训练：对抗训练[11]旨在提升模型对对抗扰动或攻击的鲁棒性。Madry *et al* [27]提供了证据表明，深度神经网络能够通过可靠的对抗训练方法抵抗对抗攻击。此外，Sinha *et al* [44]从分布鲁棒优化的角度提出了原则性的对抗训练方法。最近，Stutz *et al* [47]指出，流形上的对抗训练能够提升泛化能力，因此可以同时获得兼具鲁棒性和泛化性的模型。Peng *et al* [35]提出通过扰动样本来学习鲁棒模型。在我们的工作中，我们通过对抗训练生成“虚构”域，以提升单域泛化能力。

元学习：元学习[40, 51]是一个长期存在的课题，研究如何快速学习新概念或新任务。

少量训练样本。该方法已广泛应用于深度神经网络优化[1, 23]和少样本分类[15, 55, 46]。近期，Finn *et al*等人[6]提出了一种模型无关的元学习（MAML）流程，用于少样本学习和强化学习。MAML的目标是寻找一个好的初始化参数，使其能够在少量梯度更新步骤内快速适应新任务。Li *et al*等人[22]提出了一种基于MAML的方法来解决域泛化问题。Balaji *et al*等人[2]提出通过元学习学习自适应正则化器以实现跨域识别。然而，这些方法均不适用于单域泛化。相反，在本文中，我们提出了一种基于MAML的元学习方案，用于在“虚构”域上高效训练模型以实现单域泛化。我们证明，所学模型对未见目标域具有鲁棒性，同时也可轻松用于少样本域适应。

3. 方法

我们旨在解决单域泛化问题：模型仅在单一源域 S 上训练，但期望能在许多未见过的目标域 T 上具有良好的泛化能力。受近期诸多成果[36, 56, 24]的启发，该挑战性问题有一个有前景的解决方案是利用对抗训练[11, 49]。其核心思想是学习一个对分布外扰动具有鲁棒性的模型。更具体地说，我们可以通过求解一个最坏情况问题[44]来学习该模型：

$$\min_{\theta} \sup_{T: D(S, T) \leq \rho} \mathbb{E}[\mathcal{L}_{\text{task}}(\theta; T)], \quad (1)$$

其中 D 是衡量领域距离的相似度度量， ρ 表示 S 与 T 之间的最大领域差异。 θ 是根据任务特定目标函数 $\mathcal{L}_{\text{task}}$ 优化的模型参数。此处，我们关注使用交叉熵损失函数的分类问题：

$$\mathcal{L}_{\text{task}}(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_i y_i \log(\hat{y}_i), \quad (2)$$

其中 $\hat{\mathbf{y}}$ 是模型的*softmax*输出； $\mathbf{y}$ 是表示真实类别的独热向量； y_i 和 $\hat{y}_i$ 分别代表 $\mathbf{y}$ 和 $\hat{\mathbf{y}}$ 的第 i 维。

根据最坏情况公式(1)，我们提出了一种新方法 *Meta-Learning based Adversarial Domain Augmentation* (M-ADA)，用于单域泛化。图2展示了我们方法的概览。我们在第3.1节中通过利用对抗训练来增强源域，创建“虚构”但“具有挑战性”的域。任务模型借助Wasserstein自编码器（WAE）从域增强中学习，该自编码器在第3.2节中放宽了最坏情况约束。我们将任务模型与WAE的联合训练以及域增强过程组织在一个学习到学习的框架中。




图2. 对抗性领域增强概述。

在3.3节中描述。最后，我们在第4节中提出理论分析以证明最坏情况保证。

3.1. 对抗性域增强

我们的目标是从源域创建多个增强域。增强域需要在分布上与源域不同，以模拟未见过的域。此外，为避免增强域的发散，还应满足式(1)中定义的最坏情况保证。

为实现这一目标，我们提出对抗性域增强方法。如图2所示，我们的模型包含一个任务模型和一个WAE。在图2中，任务模型由特征提取器 $F: \mathcal{X} \rightarrow \mathcal{Z}$ （将图像从输入空间映射到嵌入空间）和分类器 $C: \mathcal{Z} \rightarrow \mathcal{Y}$ （用于从嵌入空间预测标签）组成。令 $\mathbf{z}$ 表示通过 $\mathbf{z} = F(\mathbf{x})$ 获得的 $\mathbf{x}$ 的潜在表示。整体损失函数公式如下：

$$\mathcal{L}_{\text{ADA}} = \underbrace{\mathcal{L}_{\text{task}}(\theta; \mathbf{x})}_{\text{Classification}} - \alpha \underbrace{\mathcal{L}_{\text{const}}(\theta; \mathbf{z})}_{\text{Constraint}} + \beta \underbrace{\mathcal{L}_{\text{relax}}(\psi; \mathbf{x})}_{\text{Relaxation}}, \quad (3)$$

其中 $\mathcal{L}_{\text{task}}$ 是公式(2)中定义的分类损失， $\mathcal{L}_{\text{const}}$ 是公式(1)中定义的最坏情况保证， $\mathcal{L}_{\text{relax}}$ 保证了公式(7)中定义的大规模域迁移。 ψ 是WAE的参数。 α 和 β 是两个用于平衡 $\mathcal{L}_{\text{const}}$ 和 $\mathcal{L}_{\text{relax}}$ 的超参数。

给定目标函数 $\mathcal{L}_{\text{ADA}}$ ，我们采用迭代方式在增强域 S^+ 中生成对抗样本 $\mathbf{x}^+$ ：

$$\mathbf{x}_{t+1}^+ \leftarrow \mathbf{x}_t^+ + \gamma \nabla_{\mathbf{x}_t^+} \mathcal{L}_{\text{ADA}}(\theta, \psi; \mathbf{x}_t^+, \mathbf{z}_t^+), \quad (4)$$

其中 γ 是梯度上升的学习率。只需少量迭代即可产生足够的扰动，并生成理想的对抗样本。

$\mathcal{L}_{\text{const}}$ 对抗样本施加语义一致性约束，使得 S^+ 满足 $D(S, S^+) \leq \rho_0$ 。更多




图3. $\mathcal{L}_{\text{relax}}$ 的动机。左图：若应用 $\mathcal{L}_{\text{const}}$ ，增强样本可能接近源域。中图：我们期望通过引入 $\mathcal{L}_{\text{relax}}$ 来创建域外增强。右图：这将产生一个扩大的训练域。

具体地，我们遵循[56]的方法，在嵌入空间中测量 S^+ 与 S 之间的Wasserstein距离：

$$\mathcal{L}_{\text{const}} = \frac{1}{2} \|\mathbf{z} - \mathbf{z}^+\|_2^2 + \infty \cdot \mathbf{1}\{\mathbf{y} \neq \mathbf{y}^+\}, \quad (5)$$

其中 $\mathbf{1}\{\cdot\}$ 是0-1指示函数，若 $\mathbf{x}^+$ 的类别标签与 $\mathbf{x}$ 不同，则 $\mathcal{L}_{\text{const}}$ 为 ∞ 。直观上， $\mathcal{L}_{\text{const}}$ 通过Wasserstein距离[54]控制源域外的泛化能力。然而， $\mathcal{L}_{\text{const}}$ 由于严重限制了样本与其扰动之间的语义距离，导致域迁移能力有限。因此，提出 $\mathcal{L}_{\text{relax}}$ 以放松语义一致性约束并实现大规模域迁移。 $\mathcal{L}_{\text{relax}}$ 的具体实现将在第3.2节讨论。

3.2. 瓦瑟斯坦距离约束的松弛

直观上，我们期望增强域 S^+ 与源域 S 存在显著差异。换言之，我们希望最大化 S^+ 与 S 之间的域差异。然而，语义一致性约束 $\mathcal{L}_{\text{const}}$ 会严重限制从 S 到 S^+ 的域迁移，为生成理想的 S^+ 带来新挑战。为解决此问题，我们提出 $\mathcal{L}_{\text{relax}}$ 以鼓励域外增强。我们在图3中阐述了这一思想。

具体来说，我们采用Wasserstein自编码器（WAEs）[52]来实现 $\mathcal{L}_{\text{relax}}$ 。令 V 表示由 ψ 参数化的WAE。 V 由一个编码器 $Q(\mathbf{e}|\mathbf{x})$ 和一个解码器 $G(\mathbf{x}|\mathbf{e})$ 组成，其中 $\mathbf{x}$ 和 $\mathbf{e}$ 分别表示输入和瓶颈嵌入。此外，我们使用距离度量 $\mathcal{D}_e$ 来衡量 $Q(\mathbf{x})$ 与先验分布 $P(\mathbf{e})$ 之间的散度，该度量可以通过Maximum Mean Discrepancy (MMD)或GANs[10]实现。我们可以通过优化以下目标来学习 V ：

$$\min_{\psi} [\|G(Q(\mathbf{x})) - \mathbf{x}\|^2 + \lambda \mathcal{D}_e(Q(\mathbf{x}), P(\mathbf{e}))], \quad (6)$$

其中 λ 是一个超参数。在源域 S 上离线预训练 V 后，我们将其冻结并最大化

Algorithm 1: The proposed Meta-Learning based Adversarial Domain Augmentation (M-ADA).

Input: Source domain $\mathcal{S}$; Pre-train WAE V on $\mathcal{S}$;
Number of augmented domains K

Output: Learned model parameters θ

```

1 for  $k = 1, \dots, K$  do
2   Generate  $\mathcal{S}_k^+$  from  $\mathcal{S} \cup \{\mathcal{S}_i^+\}_{i=1}^{k-1}$  using Eq. (4)
3   Re-train  $V$  with  $\mathcal{S}_k^+$ 
4   Meta-train: Evaluate  $\mathcal{L}_{\text{task}}(\theta; \mathcal{S})$  w.r.t.  $\mathcal{S}$ 
5   Compute  $\hat{\theta}$  using Eq. (8)
6   for  $i = 1, \dots, k$  do
7     Meta-test: Evaluate  $\mathcal{L}_{\text{task}}(\hat{\theta}; \mathcal{S}_i^+)$  w.r.t.  $\mathcal{S}_i^+$ 
8   end
9   Meta-update: Update  $\theta$  using Eq. (9)
10 end

```

领域增强的重构误差 $\mathcal{L}_{\text{relax}}$:

$$\mathcal{L}_{\text{relax}} = \|\mathbf{x}^+ - V(\mathbf{x}^+)\|^2. \quad (7)$$

与普通或变分自编码器[45]不同, WAEs采用Wasserstein度量来衡量输入与重建之间的分布距离。因此, 预训练的 V 能更好地捕捉源域的分布, 而最大化 $\mathcal{L}_{\text{relax}}$ 则产生较大的域迁移。补充材料中还提供了不同 $\mathcal{L}_{\text{relax}}$ 的比较。

在这项工作中, V 作为*one-class discriminator*用于区分增强是否超出源域, 这与传统GANs的判别器[10]有显著不同。同时, 它也不同于域适应中广泛使用的域分类器[24], 因为这里只有一个源域可用。因此, $\mathcal{L}_{\text{relax}}$ 与 $\mathcal{L}_{\text{const}}$ 共同用于在输入空间中“推开” $\mathcal{S}^+$, 同时在嵌入空间中“拉回” $\mathcal{S}^+$ 。在第4节中, 我们展示了 $\mathcal{L}_{\text{relax}}$ 和 $\mathcal{L}_{\text{const}}$ 分别是定义在输入空间和嵌入空间中的两个Wasserstein距离度量的推导结果。

3.3. 元学习单域泛化

为了高效组织源域 $\mathcal{S}$ 和增强域 $\mathcal{S}^+$ 上的模型训练, 我们利用元学习方案来训练单一模型。为了模拟源域 $\mathcal{S}$ 与目标域 $\mathcal{T}$ 之间的真实域偏移, 在每个学习迭代中, 我们在源域 $\mathcal{S}$ 上进行元训练, 并在所有增强域 $\mathcal{S}^+$ 上进行元测试。因此, 经过多次迭代后, 模型有望在评估时对最终目标域 $\mathcal{T}$ 实现良好的泛化。

形式上, 所提出的基于元学习的对抗性域增强 (M-ADA) 方法在训练过程的每次迭代中包含三个部分:

元训练、元测试和元更新。在元训练中, $\mathcal{L}_{\text{task}}$ 基于源域 $\mathcal{S}$ 的样本计算, 模型参数 θ 通过一个或多个学习率为 η 的梯度步骤进行更新:

$$\hat{\theta} \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}_{\text{task}}(\theta; \mathcal{S}). \quad (8)$$

然后我们在元测试中的每个增强域 $\mathcal{S}_k^+$ 上计算 $\mathcal{L}_{\text{task}}(\hat{\theta}; \mathcal{S}_k^+)$ 。最后, 在元更新中, 我们通过从联合损失中计算出的梯度来更新 θ , 其中元训练和元测试同时优化:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} [\mathcal{L}_{\text{task}}(\theta; \mathcal{S}) + \sum_{k=1}^K \mathcal{L}_{\text{task}}(\hat{\theta}; \mathcal{S}_k^+)], \quad (9)$$

其中 K 是增强域的数量。

整个训练流程总结于算法1中。我们的方法具有以下优点。首先, 与先前学习一系列集成模型的工作[56]不同, 我们的方法实现了单一模型以提高效率。在第5.4节中, 我们证明M-ADA在内存、速度和准确性方面略优于[56]。其次, 元学习方案使所学模型能够快速适应: 一个或少量梯度步骤即可在新目标域上产生改进的行为。这使得M-ADA能够用于 *few-shot domain adaptation*, 如第5.5节所示。

4. 理论理解

我们对所提出的对抗性域增强进行了详细的理论分析。具体而言, 我们证明了式(3)中定义的整体损失函数是松弛最坏情况问题的直接推导。

设 $c: \mathcal{Z} \times \mathcal{Z} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ 为攻击者在嵌入空间中 将 $\mathbf{z}$ 扰动至 $\mathbf{z}^+$ 的“成本”。设 $d: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+ \cup \{\infty\}$ 为攻击者在输入空间中 将 $\mathbf{x}$ 扰动至 $\mathbf{x}^+$ 的“成本”。 $\mathcal{S}$ 与 $\mathcal{S}^+$ 之间的Wasserstein距离可表述为: $W_c(\mathcal{S}, \mathcal{S}^+) := \inf_{M_z \in \Pi(\mathcal{S}, \mathcal{S}^+)} \mathbb{E}_{M_z}[c(\mathbf{z}, \mathbf{z}^+)]$ 和 $W_d(\mathcal{S}, \mathcal{S}^+) := \inf_{M_x \in \Pi(\mathcal{S}, \mathcal{S}^+)} \mathbb{E}_{M_x}[d(\mathbf{x}, \mathbf{x}^+)]$, 其中 M_z 和 M_x 分别为嵌入空间和输入空间中的测度; $\Pi(\mathcal{S}, \mathcal{S}^+)$ 是 $\mathcal{S}$ 与 $\mathcal{S}^+$ 的联合分布。于是, 松弛后的最坏情况问题可表述为:

$$\theta^* = \min_{\theta} \sup_{\mathcal{S}^+ \in \mathcal{D}} \mathbb{E}[\mathcal{L}_{\text{task}}(\theta; \mathcal{S}^+)], \quad (10)$$

其中 $\mathcal{D} = \{\mathcal{S}^+ : W_c(\mathcal{S}, \mathcal{S}^+) \leq \rho, W_d(\mathcal{S}, \mathcal{S}^+) \geq \eta\}$ 。我们注意到, 在Wasserstein距离度量 W_c 和 W_d 下, $\mathcal{D}$ 覆盖了一个鲁棒区域, 该区域在嵌入空间中距离 $\mathcal{S}$ 的 ρ 范围内, 且在输入空间中距离 $\mathcal{S}$ 的 η 距离之外。

对于深度神经网络, 式(10)在任意 ρ 和 η 下难以直接求解。因此, 我们考虑其具有固定惩罚参数 $\alpha \geq 0$ 和 $\beta \geq 0$ 的拉格朗日松弛形式:

$$\min_{\theta} \left\{ \sup_{\mathcal{S}^+} \left\{ \mathbb{E}[\mathcal{L}_{\text{task}}(\theta; \mathbf{x}^+)] - W_{c,d} \right\} = \mathbb{E}[\phi_{\alpha, \beta}(\theta, \psi; \mathbf{x})] \right\},$$




图4. 嵌入空间（前三幅图）和分类空间（最后一幅图）中域与凸包的可视化。从左到右依次为：(a) 源域 S 与未见过的目标域 T ；(b) 无 $\mathcal{L}_{\text{relax}}$ 的增强域 S^+ ；(c) 含 $\mathcal{L}_{\text{relax}}$ 的 S^+ ；(d) M-ADA的分类结果。不同颜色代表不同类别，数字标记对应聚类中心。注意：1为 S 的聚类中心；1+为 S^+ 的聚类中心。建议彩色查看并放大细节。

并且我们有 $W_{c,d}(S, S^+) = \alpha W_c(S, S^+) - \beta W_d(S, S^+)$ 、 $\phi_{\alpha,\beta}(\theta, \psi; \mathbf{x}) = \sup_{\mathbf{x}^+} \{\mathcal{L}_{\text{task}}(\theta; \mathbf{x}^+) - \mathcal{L}_{c,d}\}$ ，以及 $\mathcal{L}_{c,d} = \alpha c(\mathbf{z}, \mathbf{z}^+) - \beta d(\mathbf{x}, \mathbf{x}^+)$ 。因此，式(10)中的问题转化为最小化鲁棒替代项 $\phi_{\alpha,\beta}$ 。

根据[44]，当 α 足够大且Lipschitz光滑性假设成立时， ϕ_{α} 关于 θ 是光滑的。由于 ψ 与 θ 相互独立， $\phi_{\alpha,\beta}$ 关于 θ 仍然是光滑的。梯度可计算为：

$$\nabla_{\theta} \phi_{\alpha,\beta}(\theta, \psi; \mathbf{x}) = \nabla_{\theta} \mathcal{L}_{\text{task}}(\theta; \mathbf{x}^*(\mathbf{x}, \theta, \psi)),$$

其中 $\mathbf{x}^*(\mathbf{x}, \theta, \psi) = \arg \max_{\mathbf{x}^+} [\mathcal{L}_{\text{task}}(\theta; \mathbf{x}^+) - \mathcal{L}_{c,d}] = \arg \max_{\mathbf{x}^+} \mathcal{L}_{\text{ADA}}(\theta, \psi; \mathbf{x}^+, \mathbf{z}^+)$ ，这正是公式(3)中定义的对抗扰动。

5. 实验

我们首先在第5.1节和第5.2节分别介绍实验设置和实现细节。在第5.3节中，我们进行了详细的消融研究，以验证所提出松弛方法的有效性、元学习方案的效率，以及关键超参数的选择与权衡。在第5.4节中，我们将M-ADA与基准数据集上的现有最优方法进行了比较。在第5.5节中，我们进一步在few-shot domain adaptation上评估了M-ADA。

5.1. 数据集与设置

数据集与设置：(1) *Digits* 包含五个子数据集：MNIST [19]、MNIST-M [8]、SVHN [34]、SYN [8] 和 USPS [5]，每个子数据集可视为不同领域。这些数据集集中的每张图像包含单个数字，且风格各异。该数据集主要用于消融研究。我们使用MNIST训练集中的前10,000个样本进行训练，并在所有其他领域上评估模型。(2) *CIFAR-10-C* [14] 是一个鲁棒性基准测试集，包含19种损坏类型，每种类型有五个严重级别，应用于测试

CIFAR-10数据集。这些损坏来自四个主要类别：噪声、模糊、天气和数字。每种损坏有五个严重级别，其中“5”表示最严重的损坏。所有模型均在CIFAR-10上训练，并在CIFAR-10-C上评估。(3) *SYTHIA* [37] 是一个为驾驶场景中的语义分割合成的数据集。该数据集包含相同的交通场景，但位于不同地点（选择了高速公路、类似纽约的城市和欧洲老城）以及不同的天气/光照/季节条件（选择了黎明、雾天、夜晚、春季和冬季）。按照[56]中的协议，我们仅使用左前摄像头的图像，并从每个源域中随机抽取900张图像。

评估指标：对于*Digits*和CIFAR-10-C，我们计算每个未见域上的平均准确率。对于CIFAR-10-C，仅凭准确率可能不足以全面评估模型性能，还需衡量相对于基线模型（ERM [16]）的增益以及在*clean*数据集（即无任何污染的CIFAR-10测试集）上评估的相对误差。受[14]中提出的鲁棒性指标启发，我们制定了两个指标来评估域泛化背景下对图像污染的鲁棒性：平均污染误差（mCE）和相对平均污染误差（RmCE）。其定义如下： $\text{mCE} = \frac{1}{N} \sum_{i=1}^N E_i^f / E_i^{\text{ERM}}$ ， $\text{RmCE} = \frac{1}{N} \sum_{i=1}^N (E_i^f - E_{\text{clean}}^f) / (E_i^{\text{ERM}} - E_{\text{clean}}^{\text{ERM}})$ ，其中 N 是污染类型的数量。mCE用于评估分类器 f 相对于ERM [16]的鲁棒性。RmCE衡量相对于*clean*数据的相对鲁棒性。对于SYTHIA，我们计算每个未见域上的标准平均交并比（mIoU）。

5.2. 实现细节

任务模型：我们针对三个数据集设计了特定的任务模型，并相应地采用了不同的训练策略。详情请参阅补充材料。




图5. 元学习方案的验证。评估了 *Impulse Noise* (左)和 *Shot Noise* (右)上的五个严重程度等级。

Method	# of params.	Inference time	Accuracy
GUD [56]	31.9M	22.1ms	55.8%
M-ADA (full)	4.54M	3.07ms	59.5%

表1. 单域泛化中的效率比较。GUD需要学习一系列集成模型，而M-ADA利用元学习方案实现单一模型。M-ADA在内存、速度和准确性方面略优于GUD。

更多细节。对于 *Digits* 数据集，我们使用架构为 *conv-pool-conv-pool-fc-fc-softmax* 的 ConvNet [18]。所有图像被调整为 32×32 ，并将 MNIST 和 USPS 的通道复制为 RGB 图像。我们使用学习率为 $\eta = 0.0001$ 的 Adam 优化器。批次大小为 32，总迭代次数为 10,000。对于 *CIFAR-10-C*，我们使用具有 16 层且宽度为 4 的宽残差网络 (WRN) [58]。遵循 [58] 中的训练流程，我们使用带有 Nesterov 动量的 SGD，并将批次大小设为 128。初始学习率为 0.1，采用线性衰减，训练轮数为 200。对于 *SYTHIA*，我们使用以 ResNet-50 [13] 为骨干网络的 FCN-32s [25]。我们使用学习率为 $\alpha = 0.0001$ 的 Adam 优化器。批次大小设为 8，训练轮数为 50。

Wasserstein 自编码器：我们遵循 [52] 实现 WAE，但针对数据集适应性对架构进行了轻微修改。对于 *Digits* 数据集，编码器和解码器由全连接 (FC) 层构建。对于 *CIFAR-10-C* 和 *SYTHIA*，我们使用两个卷积神经网络实现自编码器。在训练 WAE 时，我们使用 WAE-GAN [52] 来最小化潜在空间中 $P(\mathbf{e})$ 和 $Q(\mathbf{e}|\mathbf{x})$ 之间的 JS 散度。一个由 FC 层实现的额外判别器用于区分来自 *true* 和 $P(\mathbf{e})$ 的点以及来自 *fake* 和 $Q(\mathbf{e}|\mathbf{x})$ 的点。由于篇幅限制，我们建议读者参考补充材料以了解详细设置。

5.3. 消融研究

验证 $\mathcal{L}_{\text{relax}}$ ：为了直观理解 $\mathcal{L}_{\text{relax}}$ 如何影响增强域分布




图6. K 和 β 的超参数调优。根据最佳分类准确率，我们将 K 设为 3， β 设为 2.0， $\times$ 设为 10^3 。

Method	Level 1	Level 2	Level 3	Level 4	Level 5
ERM [16]	87.8 $\pm$ 0.1	81.5 $\pm$ 0.2	75.5 $\pm$ 0.4	68.2 $\pm$ 0.6	56.1 $\pm$ 0.8
GUD [56]	88.3 $\pm$ 0.6	83.5 $\pm$ 2.0	77.6 $\pm$ 2.2	70.6 $\pm$ 2.3	58.3 $\pm$ 2.5
M-ADA (full)	90.5$\pm$0.3	86.8$\pm$0.4	82.5$\pm$0.6	76.4$\pm$0.9	65.6$\pm$1.2
$\uparrow$ to ERM	3.08%	6.50%	9.27%	12.0%	16.9%
$\uparrow$ to GUD	2.49%	3.95%	6.31%	8.22%	12.5%

表2. 在 *CIFAR-10-C* 上的准确率比较 (%)。随着损坏严重程度等级 (1-5) 的增加，提升效果 ($\uparrow$) 变得更加显著。

S^+ 我们使用 t-SNE [26] 在嵌入空间中可视化带有 $\mathcal{L}_{\text{relax}}$ 和不带 $\mathcal{L}_{\text{relax}}$ 的 S^+ 。其结果分别如图 4(b) 和 (c) 所示。我们观察到，带有 $\mathcal{L}_{\text{relax}}$ 的 $S \cup S^+$ 的凸包覆盖的区域比不带 $\mathcal{L}_{\text{relax}}$ 的 $S \cup S^+$ 更大。这表明 S^+ 包含更多的分布方差，并且与未见过的领域有更好的重叠。此外，我们计算 Wasserstein 距离以定量衡量 S 和 S^+ 之间的差异。带有 $\mathcal{L}_{\text{relax}}$ 的 S 和 S^+ 之间的距离为 0.078，而如果不使用 $\mathcal{L}_{\text{relax}}$ ，距离减小到 0.032，表明通过引入 $\mathcal{L}_{\text{relax}}$ 提升了 58.9%。这些结果证明 $\mathcal{L}_{\text{relax}}$ 能够将 S^+ 推离 S ，从而保证输入空间中显著的领域迁移。

元学习方案验证：表 3 和表 4 展示了 M-ADA 在有元学习 (ML) 方案下的对比结果。我们观察到，借助该元学习方案，*Digits* 和 *CIFAR-10-C* 的平均准确率分别提升了 0.94% 和 1.37%。特别地，两种未见过的损坏类型的结果如图 5 所示。可以看出，M-ADA 能够显著降低方差，并在所有严重程度等级上获得更优性能。实验结果证明，元学习方案在提升训练稳定性和分类准确率方面起着关键作用。这在具有挑战性的条件下执行对抗域增强时尤为重要。

超参数调优 K 和 β ：我们研究了 M-ADA 的两个重要超参数的影响：增强域的数量 (K) 以及源域与增强域之间的偏差 (β)。我们绘制了

Method	SVHN	MNIST-M	SYN	USPS	Avg.
ERM [16]	27.83	52.72	39.65	76.94	49.29
CCSA [31]	25.89	49.29	37.31	83.72	49.05
d-SNE [57]	26.22	50.98	37.83	93.16	52.05
JiGen [4]	33.80	57.80	43.79	77.15	53.14
GUD [56]	35.51	60.41	45.32	77.26	54.62
M-ADA w/o $\mathcal{L}_{\text{relax}}$	37.33	61.43	45.58	77.37	55.43
M-ADA w/o $\mathcal{L}_{\text{const}}$	41.36	67.28	47.94	78.22	58.70
M-ADA w/o ML	41.45	67.86	48.76	76.12	58.55
M-ADA (full)	42.55	67.94	48.95	78.53	59.49

表3. 在*Digits*上的单域泛化比较 (%)。模型在MNIST上训练。变体 (不含 $\mathcal{L}_{\text{relax}}$) 的性能下降最为显著, 表明进行Wasserstein松弛对于单域泛化至关重要。

图6中不同 K 和 β 下的准确率曲线。在图6 (左) 中, 我们发现当 $K = 3$ 时准确率达到峰值, 随后随着 K 的增加持续下降。这是因为超过一定阈值的过多对抗样本会增加不稳定性, 降低模型的鲁棒性。在图6 (右) 中, 我们观察到当 $\beta = 2.0 \times 10^3$ 时准确率达到峰值, 随着 β 的增加略有下降。这是因为较大的 β 会产生距离源域 S 过远的域, 甚至超出嵌入空间中的流形范围。

5.4. 单域泛化的评估

我们将我们的方法与以下五种最先进的方法进行比较。(1) 经验风险最小化 (ERM) [53, 16] 是使用交叉熵损失训练的模型, 没有任何辅助损失和数据增强方案。(2) CCSA [31] 使用语义对齐来正则化学习到的特征子空间, 以实现领域泛化。(3) d-SNE [57] 最小化同一类别样本之间的最大距离, 并最大化不同类别样本之间的最小距离。(4) GUD [56] 提出了一种用于单领域泛化的对抗性数据增强方法, 这是与M-ADA相关的工作。(5) JiGen [4] 学习同时分类和预测打乱图像块的顺序, 以实现领域泛化。

数字对比: 我们在MNIST上训练所有模型, 并在未见过的域*i.e.* MNIST-M、SVHN、SYN和USPS上进行测试。结果列于表3。我们观察到M-ADA在SVHN、MNIST-M和SYN上以较大优势优于GUD。在USPS上的提升不如其他域显著, 主要原因是其与MNIST的高度相似性。相反, CCSA和d-SNE在USPS上取得了较大提升, 但在其他域上表现不佳。我们还将M-ADA与GUD的集成模型进行了比较, 该集成模型聚合了多个在不同语义约束下的模型的预测结果。结果如表1所示。可以看出, M-ADA优于




图7. *SYNTHIA*上的语义分割示例[37]。从左到右: (a) 来自未见领域的图像; (b) 真实标注; (c) ERM的结果[16]; (d) GUD的结果[56]; (e) M-ADA的结果。建议彩色查看并放大以获取细节。

GUD集成模型在泛化精度方面表现优异, 但模型参数更少, 推理速度甚至更快。这些强劲的结果再次证明了所提出的学习框架的高效性。

在CIFAR-10-C上的对比: 我们在干净数据*i.e.* (即CIFAR-10) 上训练所有模型, 并在损坏数据*i.e.*, *CIFAR-10-C*上进行测试。此情况下共有19个未见过的测试域。表2展示了CIFAR-10-C上五个损坏严重程度级别的结果。可以看出, 随着严重程度增加, GUD与M-ADA之间的差距逐渐扩大, 且M-ADA能显著降低所有级别上的标准差。此外, 我们在表4中展示了每种损坏在最高严重程度下的结果。观察到M-ADA在大多数损坏类型上显著优于其他方法。特别地, 在*Snow*、*Glass blur*、*Pixelate*以及与*Noise*相关的几种损坏中, M-ADA相比ERM[16]提升超过10%。更重要的是, M-ADA在mCE和RmCE指标上取得最低值, 表明其对图像损坏具有极强的鲁棒性。

在SYNTHIA上的比较: 本实验中, Highway为源域, 而New York-like City与Old European Town为未见过的目标域。我们在表5中报告语义分割结果, 并在图7中展示部分示例。未见域来自不同地点及其他条件。我们观察到M-ADA在三个源域上的平均mIoU值最高, 表明其能够应对地点、天气和时间的变化。与另外两个数据集相比, M-ADA相对于ERM[16]和GUD[56]的提升并不显著, 这主要归因于训练图像数量有限以及对未见域的高度依赖。

5.5. 少样本领域自适应的评估

设置: 尽管M-ADA是为单域泛化设计的, 但如第3.3节所述, 我们也展示了M-ADA可以轻松应用于少样本域适应[30]。在少样本学习中, 模型通常

	Weather			Blur			Noise			Digital			Avg.	mCE	RmCE
	Fog	Snow	Frost	Zoom	Defocus	Glass	Speckle	Shot	Impulse	Jpeg	Pixelate	Spatter			
ERM [16]	65.92	74.36	61.57	59.97	53.71	49.44	41.31	35.41	25.65	69.90	41.07	75.36	56.15	1.00	1.00
CCSA [31]	66.94	74.55	61.49	61.96	56.11	48.46	40.12	33.79	24.56	69.68	40.94	77.91	56.31	0.99	0.99
d-SNE [57]	65.99	75.46	62.25	58.47	53.71	50.48	45.30	39.93	27.95	70.20	38.46	73.40	56.96	0.99	1.00
GUD [56]	68.29	76.75	69.94	62.95	56.41	53.45	38.45	36.87	22.26	74.22	53.34	80.27	58.26	0.97	0.95
M-ADA w/o $\mathcal{L}_{\text{relax}}$	66.99	80.09	74.93	54.15	44.67	60.57	59.88	59.18	43.46	76.45	53.13	80.75	61.92	0.90	0.86
M-ADA w/o ML	67.68	80.91	76.20	65.70	56.87	62.14	60.01	59.63	40.04	77.62	52.49	81.02	64.22	0.85	0.80
M-ADA (full)	69.36	80.59	76.66	68.04	61.18	61.59	60.88	60.58	45.18	77.14	52.25	80.62	65.59	0.82	0.77

表4. 在CIFAR-10-C上的鲁棒性比较[14]。模型从干净数据泛化到不同损坏情况。我们报告了在“5”级（最严重）损坏程度下19种损坏（仅展示12种）的分类准确率（%）。最后两列还报告了平均损坏误差（mCE）和相对损坏误差（RmCE）。mCE和RmCE值越低越好。

Source Domain	Method	New York-like City					Old European Town					Avg.
		Dawn	Fog	Night	Spring	Winter	Dawn	Fog	Night	Spring	Winter	
Highway/Dawn	ERM [16]	27.80	2.73	0.93	6.80	1.65	52.78	31.37	15.86	33.78	13.35	18.70
	GUD [56]	27.14	4.05	1.63	7.22	2.83	52.80	34.43	18.19	33.58	14.68	19.66
	M-ADA	29.10	4.43	4.75	14.13	4.97	54.28	36.04	23.19	37.53	14.87	22.33
Highway/Fog	ERM [16]	17.24	34.80	12.36	26.38	11.81	33.73	55.03	26.19	41.74	12.32	27.16
	GUD [56]	18.75	35.58	12.77	26.02	13.05	37.27	56.69	28.06	43.57	13.59	28.53
	M-ADA	21.74	32.00	9.74	26.40	13.28	42.79	56.60	31.79	42.77	12.85	29.00
Highway/Spring	ERM [16]	26.75	26.41	18.22	32.89	24.60	51.72	51.85	35.65	54.00	28.13	35.02
	GUD [56]	28.84	29.67	20.85	35.32	27.87	52.21	52.87	35.99	55.30	29.58	36.85
	M-ADA	29.70	31.03	22.22	38.19	28.29	53.57	51.83	38.98	55.63	25.29	37.47

表5. 在SYNTHIA[37]上的语义分割对比。模型从一个源域泛化到多个未见环境设置。我们报告标准平均交并比（mIoUs），并在图7中展示可视化结果。

Method	$ \mathcal{T} $	U $\rightarrow$ M	M $\rightarrow$ S	S $\rightarrow$ M	Avg.
I2I [33]		92.20	-	92.10	-
DIRT-T [43]		-	54.50	99.40	-
SE [7]	All	98.07	13.96	99.18	70.40
SBADA [38]		97.60	61.08	76.14	78.27
G2A [39]		90.80	-	92.40	-
FADA [30]	7	91.50	47.00	87.20	75.23
CCSA [31]	10	95.71	37.63	94.57	75.97
M-ADA	0	71.19	36.61	60.14	55.98
	7	92.33	56.33	89.90	79.52
	10	93.67	57.16	91.81	80.88

表6. 在MNIST(M), USPS(U), and SVHN(S)上的少样本领域自适应比较（准确率%）。 $|\mathcal{T}|$ 表示模型训练中使用的目标样本数量（每类）。

首先在源域S上进行预训练，然后在目标域T上进行微调。具体来说，我们首先使用所有训练图像在S上训练M-ADA。然后从T中每类随机挑选7或10张图片。这些图像用于以0.0001的学习率和16的批量大小微调预训练模型。

讨论：我们将我们的方法与当前最先进的少样本域适应方法进行了比较。我们还报告了一些使用目标域图像进行训练的无监督方法的结果。MNIST、USPS和SVHN上的结果如表6所示。我们观察到，与FADA [30]相比，M-ADA取得了具有竞争力的结果。

以及CCSA [31]。M-ADA还优于一些利用目标域未标记图像的无监督方法。更重要的是，我们注意到FADA [30]和CCSA [31]的训练方式使得S和T中的样本高度耦合。这意味着当目标域发生变化时，必须重新训练一个全新的模型。另一方面，对于新的目标域，M-ADA只需用少量样本在少量迭代次数内微调预训练模型。这展示了M-ADA的高度灵活性。

6. 结论

本文提出基于元学习的对抗性域增强（M-ADA）方法，以解决单域泛化问题。其核心思想是利用基于元学习的方案高效组织增强型“虚构”域的训练，这些域通过对抗训练生成，与源域存在分布外差异。未来，我们期望进一步扩展该工作以解决回归问题或多模式学习中的知识迁移。

参考文献

- [1] Marcin Andrychowicz, Misha Denil, Sergio Gómez, Matthew W Hoffman, David Pfau, Tom Schaul, Brendan Shillingford and Nando de Freitas. 通过

通过梯度下降进行梯度下降。载于*NeurIPS*, 第3981–3989页, 2016年。[2] Yogesh Balaji, Swami Sankaranarayanan和Rama Chellappa. Metareg: 基于元正则化的领域泛化方法。载于*NeurIPS*, 第998–1008页, 2018年。[3] Konstantinos Bousmalis, Alex Irpan, Paul Wohlhart, Yunfei Bai, Matthew Kelcey, Mrinal Kalakrishnan, Laura Downs, Julian Ibarz, Peter Pastor Sampedro, Kurt Konolige, Sergey Levine和Vincent Vanhoucke. 利用仿真与领域自适应提升深度机器人抓取效率。载于*ICRA*, 第4243–4250页, 2018年。[4] Fabio M Carlucci, Antonio D’Innocente, Silvia Bucci, Barbara Caputo和Tatiana Tommasi. 通过拼图游戏实现领域泛化。载于*CVPR*, 第2229–2238页, 2019年。[5] John S Denker, WR Gardner, Hans Peter Graf, Donnie Henderson, Richard E Howard, W Hubbard, Lawrence D Jackel, Henry S Baird和Isabelle Guyon. 手写邮政编码数字的神经网络识别器。载于*NeurIPS*, 第323–331页, 1989年。[6] Chelsea Finn, Pieter Abbeel和Sergey Levine. 用于深度网络快速适应的模型无关元学习。载于*ICML*, 第1126–1135页, 2017年。[7] Geoffrey French, Michal Mackiewicz和Mark Fisher. 用于视觉领域自适应的自集成方法。载于*ICLR*, 2018年。[8] Yaroslav Ganin和Victor Lempitsky. 通过反向传播的无监督领域自适应。载于*ICML*, 第1180–1189页, 2015年。[9] Muhammad Ghifary, W Bastiaan Kleijn, Mengjie Zhang和David Balduzzi. 基于多任务自编码器的目标识别领域泛化。载于*ICCV*, 第2551–2559页, 2015年。[10] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville和Yoshua Bengio. 生成对抗网络。载于*NeurIPS*, 第2672–2680页, 2014年。[11] Ian J Goodfellow, Jonathon Shlens和Christian Szegedy. 解释并利用对抗样本。载于*ICLR*, 2015年。[12] Thomas Grubinger, Adriana Birlutiu, Holger Schöner, Thomas Natschläger和Tom Heskes. 用于领域泛化的多领域迁移成分分析。载于*Neural Processing Letters (NPL)*, 46(3):845–855, 2017年。[13] Kaiming He, Xiangyu Zhang, Shaoqing Ren和Jian Sun. 用于图像识别的深度残差学习。载于*CVPR*, 第770–778页, 2016年。[14] Dan Hendrycks和Thomas Dietterich. 评估神经网络对常见损坏和扰动的鲁棒性基准。载于*ICLR*, 2019年。[15] Gregory Koch, Richard Zemel和Ruslan Salakhutdinov. 用于单样本图像识别的孪生神经网络。载于*ICML Deep Learning Workshop*, 2015年。[16] Vladimir Koltchinskii. *Oracle Inequalities in Empirical Risk Minimization and Sparse Recovery Problems: Ecole d’Eté de Probabilités de Saint-Flour XXXVIII-2008*, 卷2033. Springer Science & Business Media, 2011年。

[17] 杨立昆、约书亚·本吉奥、杰弗里·辛顿. 深度学习。载于*Nature Cell Biology (NCB)*, 521(7553):436–444, 2015年5月。[18] 杨立昆、伯恩哈德·博瑟、约翰·S·登克、唐尼·亨德森、理查德·E·霍华德、韦恩·哈伯德、劳伦斯·D·杰克尔. 反向传播在邮政编码识别中的应用。载于*Neural Computation (NC)*, 1(4):541–551, 1989年。[19] 杨立昆、L昂·布图、约书亚·本吉奥、帕特里克·哈夫纳. 基于梯度的学习在文档识别中的应用。载于*Proceedings of the IEEE*, 86(11):2278–2324, 1998年。[20] 李在浩、马克西姆·拉金斯基. 基于Wasserstein距离的极小极大统计学习。载于*NeurIPS*, 第2687–2696页, 2018年。[21] 李达、杨永信、宋一哲、蒂莫西·M·霍斯佩达莱斯. 更深、更广、更艺术的领域泛化。载于*ICCV*, 第5542–5550页, 2017年。[22] 李达、杨永信、宋一哲、蒂莫西·M·霍斯佩达莱斯. 学会泛化：面向领域泛化的元学习。载于*AAAI*, 2018年。[23] 柯力、吉滕德拉·马利克. 学习优化。载于*ICLR*, 2017年。[24] 刘宏、龙明盛、王建民、迈克尔·乔丹. 可迁移对抗训练：一种适应深度分类器的通用方法。载于*ICML*, 第4013–4022页, 2019年。[25] 乔纳森·朗、埃文·谢尔哈默、特雷弗·达雷尔. 用于语义分割的全卷积网络。载于*CVPR*, 第3431–3440页, 2015年。[26] 劳伦斯·范德马滕、杰弗里·辛顿. 使用t-SNE可视化数据。载于*Journal of Machine Learning Research (JMLR)*, 9(11月):2579–2605, 2008年。[27] 亚历山大·马德里、亚历山大·马凯洛夫、路德维希·施密特、迪米特里斯·齐普拉斯、阿德里安·弗拉杜. 迈向抵抗对抗攻击的深度神经网络模型。载于*ICLR*, 2018年。[28] 马西米利亚诺·曼奇尼、塞缪尔·罗塔·布尔奥、芭芭拉·卡普托、埃莉萨·里奇. 最佳源前向：通过源特定网络实现领域泛化。载于*ICIP*, 第1353–1357页, 2018年。[29] 马西米利亚诺·曼奇尼、塞缪尔·罗塔·布尔奥、芭芭拉·卡普托、埃莉萨·里奇. 基于深度领域泛化的鲁棒地点分类。载于*IEEE Robotics and Automation Letters (RAL)*, 3(3):2093–2100, 2018年。[30] 赛义德·莫蒂安、奎因·琼斯、赛义德·伊拉曼内什、吉安弗兰科·多雷托. 少样本对抗领域自适应。载于*NeurIPS*, 第6670–6680页, 2017年。[31] 赛义德·莫蒂安、马尔科·皮奇里利、唐纳德·A·阿杰罗、吉安弗兰科·多雷托. 统一的深度监督领域自适应与泛化。载于*ICCV*, 第5715–5725页, 2017年。[32] 克里卡莫尔·穆安德特、大卫·巴尔杜齐、伯恩哈德·施奥尔科普夫. 通过不变特征表示实现领域泛化。载于*ICML*, 第10–18页, 2013年。[33] 扎克·穆雷兹、索海尔·科洛里、大卫·克里格曼、拉维·拉马莫尔蒂、金庆南. 面向领域自适应的图像到图像翻译。载于*CVPR*, 第4500–4509页, 2018年。[34] 尤瓦尔·内策尔、王涛、亚当·科茨、亚历山德罗·比萨科、吴波、吴恩达. 自然场景中的数字读取

使用无监督特征学习的图像。 *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011.

[35] Xi Peng, Zhiqiang Tang, Fei Yang, Rogerio S Feris, 和 Dimitris Metaxas. 联合优化数据增强与网络训练: 人体姿态估计中的对抗性数据增强. *CVPR*, 第2226–2234页, 2018. [36] Alexander J Ratner, Henry Ehrenberg, Zeshan Hussain, Jared Dunnmon, 和 Christopher Ré. 学习组合领域特定变换用于数据增强. *NeurIPS*, 第3236–3246页, 2017. [37] German Ros, Laura Sellart, Joanna Materzynska, David Vazquez, 和 Antonio M Lopez. synthia数据集: 用于城市场景语义分割的大规模合成图像集合. *CVPR*, 第3234–3243页, 2016. [38] Paolo Russo, Fabio M Carlucci, Tatiana Tommasi, 和 Barbara Caputo. 从源域到目标域再返回: 对称双向自适应生成对抗网络. *CVPR*, 第8099–8108页, 2018. [39] Swami Sankaranarayanan, Yogesh Balaji, Carlos D Castillo, 和 Rama Chellappa. 生成以适应: 使用生成对抗网络对齐域. *CVPR*, 第8503–8512页, 2018. [40] Jürgen Schmidhuber. *Evolutionary principles in self-referential learning*. 博士论文, 慕尼黑工业大学, 1987. [41] Shiv Shankar, Vihari Piratla, Soumen Chakrabarti, Siddhartha Chaudhuri, Preethi Jyothi, 和 Sunita Sarawagi. 通过跨梯度训练实现跨域泛化. *ICLR*, 2018. [42] Ashish Shrivastava, Tomas Pfister, Oncel Tuzel, Josh Susskind, Wenda Wang, 和 Russell Webb. 通过对抗训练从模拟和无监督图像中学习. *CVPR*, 第2242–2251页, 2017. [43] Rui Shu, Hung H Bui, Hirokazu Narui, 和 Stefano Ermon. 无监督域适应的dirt-t方法. *ICLR*, 2018. [44] Aman Sinha, Hongseok Namkoong, 和 John Duchi. 通过原则性对抗训练验证分布鲁棒性. *ICLR*, 2018. [45] Jake Snell, Kevin Swersky, 和 Richard Zemel. 自编码变分贝叶斯. *ICLR*, 2014. [46] Jake Snell, Kevin Swersky, 和 Richard Zemel. 用于少样本学习的原型网络. *NeurIPS*, 第4077–4087页, 2017. [47] David Stutz, Matthias Hein, 和 Bernt Schiele. 解耦对抗鲁棒性与泛化. *CVPR*, 第6976–6987页, 2019. [48] Masashi Sugiyama 和 Amos J Storkey. 协变量偏移的混合回归. *NeurIPS*, 第1337–1344页, 2007. [49] Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, Joan Bruna, Dumitru Erhan, Ian Goodfellow, 和 Rob Fergus. 神经网络的迷人性质. *ICLR*, 2014. [50] Zhiqiang Tang, Xi Peng, Tingfeng Li, Yizhe Zhu, 和 Dimitris N Metaxas. 自适应数据变换. *ICCV*, 第2998–3006页, 2019. [51] Sebastian Thrun 和 Lorien Pratt. *Learning to learn*. Springer Science & Business Media, 2012.

[52] I Tolstikhin, O Bousquet, S Gelly, 和 B Schölkopf. Wasserstein 自编码器. 载于 *ICLR*, 2018. [53] Vladimir Vapnik 和 Vladimir Vapnik. 统计学习理论, 1998. [54] Cédric Villani. *Topics in optimal transportation*. 第58卷. 美国数学学会, 2003. [55] Oriol Vinyals, Charles Blundell, Timothy Lillicrap, 和 Daan Wierstra. 用于单次学习的匹配网络. 载于 *NeurIPS*, 页码 3630–3638, 2016. [56] Riccardo Volpi, Hongseok Namkoong, Ozan Sener, John C Duchi, Vittorio Murino, 和 Silvio Savarese. 通过对抗性数据增强泛化到未见领域. 载于 *NeurIPS*, 页码 5334–5344, 2018. [57] Xiang Xu, Xiong Zhou, Ragav Venkatesan, Gurumurthy Swaminathan, 和 Orchid Majumder. d-sne: 使用随机邻域嵌入的领域自适应. 载于 *CVPR*, 页码 2497–2506, 2019. [58] Sergey Zagoruyko 和 Nikos Komodakis. 宽残差网络. 载于 *BMVC*, 2016. [59] Long Zhao, Xi Peng, Yuxiao Chen, Mubbasir Kapadi, 和 Dimitris Metaxas. 知识作为先验: 无监督知识的数据集跨模态知识泛化. 载于 *CVPR*, 2020. [60] Long Zhao, Xi Peng, Yu Tian, Mubbasir Kapadia, 和 Dimitris N. Metaxas. 用于3D人体姿态回归的语义图卷积网络. 载于 *CVPR*, 页码 3425–3435, 2019.

附录A. 实验细节

任务模型：我们根据三个数据集的特点，设计了特定的任务模型并采用了不同的训练策略。

在Digits数据集中，模型架构为`conv-pool-conv-pool-fc-fc-softmax`。有两个 5×5 的卷积层，分别具有64和128个通道。每个卷积层后接一个大小为 2×2 的最大池化层。两个全连接层的大小为1024，softmax层的大小为10。

在CIFAR-10-C [14]中，我们使用宽度为4的16层宽残差网络（WRN）[58]。第一层是一个 3×3 卷积层，它将原始图像的3个通道转换为16个通道的特征图。然后特征经过三组 3×3 卷积层。每组包含两个块，每个块由两个通道数相同的卷积层组成，其通道数分别为{64、128、256}。每个卷积层后接批量归一化（BN）。第三组的输出后附加一个大小为 8×8 的平均池化层。最后，一个大小为10的softmax层预测类别分布。

在SYTHIA [37]中，我们使用FCN-32s [25]，其主干网络为ResNet-50 [13]。该模型以ResNet-50为起点。附加一个具有14个通道的 1×1 卷积层，用于在每个粗输出位置预测每个类别的得分。随后是一个反卷积层，通过双线性插值将粗输出上采样至原始尺寸。

Wasserstein自编码器：我们遵循[52]实现WAE，但根据三个数据集的特点对其架构进行了轻微修改。

在Digits数据集中，编码器和解码器由全连接层构建。编码器包含两个全连接层，大小分别为400和20。相应地，解码器包含两个全连接层，大小分别为400和3072。判别器包含两个全连接层，大小分别为128和1。其架构如图8(a)所示。

在CIFAR-10-C [14]中，编码器以四个卷积层开始，通道数为{16, 32, 32, 32}。随后是两个全连接层，大小分别为1024和512。相应地，解码器以两个全连接层开始，大小分别为512和1024。随后是四个反卷积层，通道数为{32, 32, 16, 3}。除了解码器的最后一层外，每一层后都接有BN。判别器由两个全连接层组成，大小分别为128和1。该架构如图8(b)所示。

在SYTHIA [37]中，编码器从三个卷积层开始，通道数分别为{32、64、128}。随后是两个全连接层，尺寸为{3840、512}。相应地，解码器从两个全连接层开始，其

的大小为512、3840}。随后是三个通道数分别为{64、32、3}的反卷积层。除解码器的最后一层外，每一层后都接有BN。判别器由三个大小分别为{512、512、1}的全连接层组成。该架构如图8(c)所示。

我们在训练WAE时使用Adam优化器。Digits的学习率为0.001，CIFAR-10-C和SYTHIA的学习率均为0.0001。Digits的训练轮数为20，CIFAR-10-C [14]为100，SYTHIA [37]为200。

附录B. 附加实验结果

B.1. 消融实验

元学习方案的验证：四种未见过的损坏类型的结果如图9所示。可以看出，M-ADA能够显著降低方差，并在所有严重程度取得更好的性能。实验结果证明，元学习方案在提高训练稳定性和分类准确性方面起着关键作用。这在具有挑战性的条件下进行对抗性域增强时尤为重要。

K 、 α 和 β 的超参数调优：我们研究了M-ADA三个重要超参数的影响：增强域的数量（ K ）、源域与增强域在嵌入空间中的距离（ α ），以及源域与增强域之间的偏差（ β ）。我们在图10中绘制了不同 K 、 α 和 β 下的准确率曲线。在图10（左）中，我们发现当 K = 3时准确率达到峰值，并随着 K 的增加持续下降。这是因为超过一定阈值的过多对抗样本会增加不稳定性，降低模型的鲁棒性。由于增强域与源域之间的距离随 K 增大而增加，较大的 K 可能破坏语义一致性的约束，导致模型训练效果不佳。在图10（中）中，我们发现当 α = 1.0时准确率达到峰值，并随着 α 的增加持续下降。这是因为较大的 α 会使源域与增强域在嵌入空间中过于接近，导致域迁移受限。在图10（右）中，我们观察到当 β = 2.0×10^3 时准确率达到峰值，并随着 β 的增加略有下降。这是因为较大的 β 会产生距离源域 S 过远的域，甚至超出嵌入空间中的流形。

B.2. 不同 $\mathcal{L}_{\text{relax}}$ 的比较

WAEs采用Wasserstein度量来衡量输入与重建之间的分布距离，这对于域增强非常理想。因此，重建误差 $\mathcal{L}_{\text{relax}} = \|\mathbf{x}^+ - V(\mathbf{x}^+)\|^2$ 指示了 $\mathbf{x}^+$ 是否与 $\mathbf{x}$ 处于同一分布。使用WAE替代普通AE是实现这一目标的关键设计（表7）。此外，




图8. WAE的架构。从左到右：(a) 用于*Digits*的WAE；(b) 用于*CIFAR-10-C*的WAE [14]；(c) 用于*SYTHIA*的WAE [37]。注意：“+”：判别器的正样本；“-”：判别器的负样本。




图9. 元学习方案的验证。对每种未见过的损坏评估五个严重等级。从左到右：(a) *Gaussian Noise*；(b) *Speckle Noise*；(c) *Impulse Noise*；(d) *Shot Noise*。

我们的实验表明， $\|V(\mathbf{x}) - V(\mathbf{x}^+)\|^2$ 具有更好的松弛效果，并提高了精度。在应用了Wasserstein先验的重建空间中，分布距离更为可靠。

	$\ \mathbf{x} - \mathbf{x}^+\ ^2$	Vanilla AE	WAE
Digits	55.71%	58.67%	59.49%
CIFAR-10-C	62.03%	63.34%	65.59%

表7. 使用不同松弛项的精度比较。

B.3. 在CIFAR-10-C上的比较

我们在干净数据*i.e.*、CIFAR-10上训练所有模型，并在损坏数据*i.e.*、*CIFAR-10-C*上进行测试。此情况下共有19个未见过的测试域。我们在表8中展示了每种损坏在最高严重程度下的结果。我们观察到M-ADA在大多数损坏上显著优于其他方法。特别是在*Frost*、*Glass blur*、*Gaussian blur*、*Pixelate*以及与*Noise*相关的几种损坏中，M-ADA相比ERM[16]提升了超过10%。更重要的是，M-ADA在mCE和相对mCE上取得了最低值，表明其对图像损坏具有很强的鲁棒性。




图10. K 、 α 和 β 的超参数调优。根据最佳准确率，我们将 K = 设为3， α = 设为1.0， β = 设为 2.0×10^3 。

	Weather			Blur					Noise			
	Fog	Snow	Frost	Zoom	Defocus	Glass	Gaussian	Motion	Speckle	Shot	Impulse	Gaussian
ERM [16]	65.92	74.36	61.57	59.97	53.71	49.44	30.74	63.81	41.31	35.41	25.65	29.01
CCSA [31]	66.94	74.55	61.49	61.96	56.11	48.46	32.22	64.73	40.12	33.79	24.56	27.85
d-SNE [57]	65.99	75.46	62.25	58.47	53.71	50.48	33.06	63.70	45.30	39.93	27.95	34.02
GUD [56]	68.29	76.75	69.94	62.95	56.41	53.45	38.33	63.93	38.45	36.87	22.26	32.43
M-ADA w/o $\mathcal{L}_{\text{relax}}$	66.99	80.09	74.93	54.15	44.67	60.57	30.53	57.06	59.88	59.18	43.46	55.07
M-ADA w/o ML	67.68	80.91	76.20	65.70	56.87	62.14	41.20	63.86	60.01	59.63	40.04	55.70
M-ADA (full)	69.36	80.59	76.66	68.04	61.18	61.59	47.34	64.23	60.88	60.58	45.18	56.88

	Digital									
	Jpeg	Pixelate	Spatter	Elastic	Brightness	Saturate	Contrast	Avg.	mCE	RmCE
ERM [16]	69.90	41.07	75.36	72.40	91.25	89.09	36.87	56.15	1.00	1.00
CCSA [31]	69.68	40.94	77.91	72.36	91.00	89.42	35.83	56.31	0.99	0.99
d-SNE [57]	70.20	38.46	73.40	73.33	90.90	89.27	36.28	56.96	0.99	1.00
GUD [56]	74.22	53.34	80.27	74.64	89.91	82.91	31.55	58.26	0.97	0.95
M-ADA w/o $\mathcal{L}_{\text{relax}}$	76.45	53.13	80.75	73.85	90.86	87.01	27.83	61.92	0.90	0.86
M-ADA w/o ML	77.62	52.49	81.02	75.54	90.69	86.58	26.30	64.22	0.85	0.80
M-ADA (full)	77.14	52.25	80.62	75.61	90.78	87.62	29.71	65.59	0.82	0.77

表8. 主论文中表4的完整版本。模型从干净数据泛化到不同损坏类型。我们报告了在损坏等级“5”（最严重）下19种损坏的分类准确率（%）。最后两列还报告了平均损坏误差（mCE）和相对平均损坏误差（RmCE）。mCE和RmCE越低越好。